

Manual de Usuario Andes Data Program

28/11/2023



Versión	Descripción Cambios	Autor	Fecha	Revisado Por
1.0	Creación	Jonathan Tautiva, Diana Garnica	15/12/2022	Diego Bastias
2.0	Actualización de contenido	Diego Bastias	24-11-2023	Diego Bastias
2.1	Cambio de formato de documento	Diego Bastias	28-11-2023	Diego Bastias

Contenido

• <u>Introducción</u>	<u>4</u>
¿Qué es el Andes Data Program (ADP)?	4
¿Qué no es el ADP?	4
• <u>Estructura y Funcionamiento del ADP</u>	<u>5</u>
Procesos de carga de datos	5
Chile	5
Colombia	5
Ecuador	5
Proceso de actualización de Data Warehouse y Data Mart	5
Esquemas del ADP	6
Raw Data	6
Data Warehouse	6
Sandbox	6
Modelo de datos del ADP	6
Tablas de dimensiones	7
Tablas de hechos	7
• <u>¿Cómo usar el ADP?</u>	<u>7</u>
Obtener un usuario ADP	7
Descarga de Aplicativos aprobados	7
Configuración del ADP	8
DB Visualizer	8
DBever	9
Ktime	9
Python	10
• <u>Consideraciones a la hora de usar el ADP</u>	<u>11</u>
• <u>Índice de diagramas e ilustraciones</u>	<u>12</u>
• <u>Índice de tablas</u>	<u>12</u>

Introducción


En este manual se encuentra la información necesaria para acceder al entorno de trabajo del Andes Data Program, así como su funcionamiento e implementación en actividades propias del negocio que requieran el consumo de datos para la gestión eficiente de sus operaciones.

¿Qué es el Andes Data Program (ADP)?

Este manual de usuario contiene el detalle de la estructura general y funcionamiento del repositorio oficial de datos de Liberty denominado **Andes Data Program (ADP)**.

El Andes Data Program es un entorno oficial de datos propiedad de Liberty, el cual busca entregar los datos con objetivo analítico a usuarios de negocio, actuaría, distribución y otros, de una manera estandarizada, estructurada y gobernada.

Ilustración 1.- Diagrama “end to end” de datos ADP (2023)



Para esto, se extraen los datos desde diversas fuentes de origen, subiéndolos a la nube en un entorno de Amazon Web Service (AWS). La primera capa, denominada ODS o Raw Data, contiene la información tal cual está en el origen. Luego, se estructura esta data para ser dispuesta en vistas de consumo a usuarios intermedios o finales para analítica o reportaría.

¿Qué no es el ADP?

El ADP **NO** es un repositorio de datos en tiempo real u operacional. Los procesos de carga de datos desde el origen se dan, en su mayoría, una vez al día en horario nocturno de los países correspondientes. Esto es para optimizar los tiempos de carga y no perjudicar la performance del Data Warehouse de cara a los usuarios. Es por eso que la información contenida será con un delay de un día.

Estructura y Funcionamiento del ADP

Procesos de carga de datos

Chile

En Chile, la carga de datos comienza a las 00:00AM hora local, cada día. En este proceso se obtienen de manera incremental¹ los datos en bruto desde los diferentes orígenes de datos como Oracle (Axis), Dynamo (AWS), Aurora (AWS), entre otros. Estos pueden ser extraídos de manera directa o por un proceso intermedio. El proceso de carga completo termina aproximadamente a las 4AM, hora en la cual comienza la actualización del Data Warehouse y Data Mart **(Ver apartado de actualización de Data Warehouse y Data Mart)**

Cabe mencionar que Chile, además de los datos mencionados anteriormente, posee “data muerta”. Esta es data que ya no sufrirá cambios en el tiempo. Estos datos eran originalmente de la empresa Penta Seguros.

Colombia

Similar a Chile, en Colombia la carga de datos comienza a las 00:00AM hora local, cada día. La fuente de datos es Oracle, AS400, Earnix, entre otros. En este caso, sólo Oracle es obtenido de manera directa. AS400, Earnix y otros se obtienen mediante un proceso intermedio y subidos al “bucket S3”. El proceso de carga completo termina aproximadamente a las 7AM (hora local), hora en la cual comienza la actualización del Data Warehouse y Data Mart **(Ver apartado de actualización de Data Warehouse y Data Mart)**

Ecuador

Los datos de Ecuador se mantienen, por el momento, solo como Raw Data. Estos son cargados como carga total o “full load”² debido a su incapacidad de generar un log de carga.

Proceso de actualización de Data Warehouse y Data Mart

Posterior a los procesos de carga, se comienzan a ejecutar las cargas o refrescos de las vistas de consumo a los usuarios, almacenadas en los datawarehouse o data mart. Si bien, la mayoría de las vistas se refrescan diariamente, existen algunas (principalmente relacionadas con los cierres contables) que actualizan su información una vez al mes. Dentro de las más importantes se señalan:

- Margen (Chile)
- Snapshot (Chile)
- Perfiles de Reaseguros (Chile)
- Risk KPI (Colombia)

¹ Carga Incremental: Se cargan solo los datos nuevos según un log o registro

² Carga Total o Full Load: Se carga toda la data histórica en cada proceso



Esquemas del ADP

Los esquemas que contiene el ADP están divididos según su naturaleza y niveles de acceso. Así, es factible poder dejar esquemas orientados a la carga, a los datos personales, a pruebas de laboratorio, etc. Asimismo, estos esquemas se pueden bloquear para ciertos usuarios, dar accesos temporales o mantener accesos de administrador.

A continuación, se menciona el tipo de dato o ambiente y dentro se mencionarán los esquemas que representan

Raw Data

Como se mencionó anteriormente, la Raw Data es una copia de los datos como se encuentran en su origen. Denominados ODS (Operational Data Store), en el ADP existen dos:

- **cdp_ods**: esquema que se concentra en la raw data de Chile
- **gde_adp_ods**: esquema orientado a la raw data de Andino (Colombia y Ecuador)

Data Warehouse

Esquemas donde se almacenan las vistas orientadas a los usuarios intermedios (reportería) o finales (analítica o de consumo directo de datos). Estos, al igual que la raw data, están divididos en Chile y Andino. Sin embargo, tienen dos subdivisiones más: si contienen **datos PII**³ o si están en **inglés**. Así, la disposición de esquemas quedará como sigue:

Idioma	Tipo de dato	Chile	Andino
Español	PII	cdp_dwh_spsv	gde_adp_dwh_spvw_general
	Non PII	cdp_dwh_spv	gde_adp_dwh_spvw_restricted
Inglés	PII	cdp_dwh_sv	gde_adp_dwh_vw_general
	Non PII	cdp_dwh_v	gde_adp_dwh_vw_restricted

Tabla 1.- Esquemas de vistas ADP (2023)

Sandbox

Ambiente de pruebas a disposición de ciertos usuarios. La idea es poder probar nuevas formas de data mart que, bajo gobernanza, puedan ser pasados a ambiente productivo. La duración de la data en el sandbox es de veinte días.

Modelo de datos del ADP


El modelo de datos del ADP, para las vistas de consumo, es un modelo estrella. Es decir, de una tabla de hechos o transacciones se desprenden las tablas dimensionales que entregarán la información necesaria para categorizar el hecho. La conexión entre estas vistas se da por una llave única o “key”, para las vistas en inglés. Estas llaves son números aleatorios generados en sistema por una conexión lógica y, como se mencionó anteriormente, sirven exclusivamente para conectar las tablas. **En**

³ Dato PII: Personally Identifiable Information o información de identificación personal. Es un dato privado que hace referencia a una persona y cualquier forma de identificación. Ej. RUT, NIT, Dirección, etc.



ninguna circunstancia deben ser utilizadas como filtro de datos, pues en caso de reseteo en el ADP, estas llaves se verán modificadas.

Ilustración 2.- Diagrama relacional de ejemplo – ADP (2023)



Tablas de dimensiones

Así mismo, las tablas dimensionales también contienen uno o más serial keys para su conexión a las fact tables u otras dimensionales, junto con atributos adicionales que varían según el objetivo de cada tabla dimensional para aportar con la descripción de una tabla de hechos.

Tablas de hechos

Las fact tables (tablas de hechos o transaccionales) en el ADP contienen principalmente, columnas denominadas serial key (llaves de conexión), las cuales permiten la conexión con las tablas dimensionales. Además, también contienen información transaccional según el objetivo de cada tabla, que serán explicadas más adelante en este manual.

¿Cómo usar el ADP?

Obtener un usuario ADP

Obtener el usuario de redshift para conectarse al ADP es bastante simple. Se debe levantar un ticket el cual, se darán accesos según el perfil de usuario, permitiendo o no el acceso a datos PII, por ejemplo.

Descarga de Aplicativos aprobados

Para conectarse al ADP, se debe tener una interfaz para manejar dato. Estos pueden ser: **DB Visualizer, DBeaver, R, Python, Knime**, entre otros. Todos estos pueden ser adquiridos a través de [Liberty Application Portal](https://applications.lmig.com/esd)⁴.

⁴ URL de Liberty Application Portal: <https://applications.lmig.com/esd>




Configuración del ADP

DB Visualizer

Para generar una nueva conexión a una base de datos se debe ir a la pestaña Database y luego a la opción "Create Database Connection". Si aparece el mensaje "Create Database Connection using the Connection Wizard", marcar la opción "No Wizard".

Ilustración 3.- Pasos para configurar DB Visualizer (2023)




Una vez realizado lo anterior, se despliega la vista de configuración de la base de datos en blanco. Los espacios a rellenar son

- **Name:** a criterio del usuario. Servirá para identificarlo si tiene otra conexión
- **Database Type:** Redshift
- **Driver (JDBC):** Redshift
- **Database Server:** intl-andesmcm-digital-eco-dataplatform-datamart-prod.czjshh2jedqq.us-east-1.redshift.amazonaws.com
- **Database Port:** 9519
- **Database:** adp_dwh

Por último, las credenciales de autenticación (usuario y contraseña) proporcionadas por el equipo de administración del ADP. A continuación, se muestra un ejemplo de cómo hacer esto:


Ilustración 4.- Parámetros de configuración ADP (2023)



DBeaver

El proceso es similar al DB Visualizer. Los parámetros son similares:


Ilustración 5.- Parámetros de configuración de DBeaver (2023)



Knime

Para generar una nueva conexión a un lienzo de Knime, es necesario descargar la extensión apropiada desde la opción File y luego “Install Knime Extensions”. Una vez se abra la ventana de extensiones, en el buscador se debe escribir “Redshift”, para ubicar la extensión **KNIME Amazon Redshift Connector And Tools**. Una vez ubicado se selecciona y clic en siguiente para finalizar.


Ilustración 6.- Obtención de Nodo Redshift para Knime (2023)



Nota: El proceso de descarga de esta extensión puede fallar en algunos casos debido a un archivo inválido al adquirir Knime del portal de aplicaciones. Si ocurre lo anterior, favor ponerse en contacto con el equipo de IT.

El paso anterior permitirá importar el nodo “Amazon Redshift Connector”, el cual se debe obtener en cada nuevo proyecto. Luego, se debe hacer clic derecho sobre el nodo y luego presionar “configurar”. En la ventana que se desplegará, debemos establecer la conexión como se muestra a continuación:

Ilustración 7.- Configuración del Nodo Redshift para Knime (2023)



Una vez configurado el nodo, hacer clic en ejecutar y el nodo cambiara a luz verde, señal de que ahora está conectado al ADP desde Knime.

Python

Para manejar el ADP desde Python, se requerirán unas librerías que serán llamadas en el setup:

```
import getpass
import psycopg2
```

Luego, se debe ejecutar el siguiente comando:

```
#ADP
username = input("Enter User Name: ")
password = getpass.getpass("Enter Password: ")
adp = psycopg2.connect(dbname = 'adp_dwh', host = 'intl-andesmcm-digital-eco-dataplatform-
datamart-prod.czshh2jedq.us-east-1.redshift.amazonaws.com',
port = '9519', user = username, password = password)
```

Esto generará una ventana donde se deberá escribir el nombre de usuario, seguido de la contraseña. Este paso se deberá hacer cada vez que se inicie Python, por lo que es crítico recordar la contraseña y usuario.

Consideraciones a la hora de usar el ADP

- El ADP se bloquea a la hora de carga de datos. Es decir, no se podrán dejar corriendo queries durante la noche, pues éstas se botarán en un proceso automático.
- Todo usuario que tenga datos en sandbox se hará responsable de esos datos, de **no usarlos como información oficial** y que ésta será solo transitoria.
- Aproximadamente dos veces al año se realiza un Disaster Recovery Plan (DRP), ejecutado por TI. Este proceso migra las bases a servidores de respaldo. Como consecuencia, es probable que se pierdan los “log” de carga incremental, por lo que se debe recurrir a una carga completa para el país que le corresponda. Si esto llegase a ocurrir, se enviarán las comunicaciones correspondientes en el menor tiempo posible.
- ADP Key People:
 - Diego Bastias Coordinador Data Program
 - Guillermo Nielsen Arquitecto Data Program
 - Pamela Miranda Coordinadora de Gobierno de Datos
 - Francisco Guerrero Ingeniero de seguridad de la información

Índice de diagramas e ilustraciones

Ilustración 1.- Diagrama “end to end” de datos ADP (2023)	4
Ilustración 2.- Diagrama relacional de ejemplo – ADP (2023)	7
Ilustración 3.- Pasos para configurar DB Visualizer (2023)	8
Ilustración 4.- Parámetros de configuración ADP (2023)	8
Ilustración 5.- Parámetros de configuración de DBeaver (2023)	9
Ilustración 6.- Obtención de Nodo Redshift para Knime (2023)	9
Ilustración 7.- Configuración del Nodo Redshift para Knime (2023)	10

Índice de tablas

Tabla 1.- Esquemas de vistas ADP (2023)	6
---	---

